

깁스 샘플링

ToBig's 9기 이영걸

Gibbs Sampling

다양한 알고리즘과 방법론을 중심으로

Contents

Unit 01 | Monte Carlo & Markov Chain

Unit 02 | MCMC : Metropolis-Hastings

Unit 03 | MCMC : Gibbs Sampling

Unit 01 | Monte Carlo & Markov Chain

‘몬테 카를로 방법’

무작위 추출된 난수를 이용해 원하는 함수의 값을 계산하기 위한 시뮬레이션 방법이다.

자유도가 높거나 닫힌 꼴(closed form)의 해가 없는 문제들에 널리 쓰이는 방법이지만,


어느 정도의 오차를 감안해야만 하는 특징이 있다.

무작위로 뽑힌 난수의 개수가 늘어날수록 더 정확한 결과를 얻을 수 있으나, 그만큼 더 많은 시간이 걸리는 것을 감안해야 한다.

또한 시뮬레이션 기반 방법이기 때문에, 해석적인 방법과 달리 항상 어느 정도 오차가 있을 수 있음을 감안해야만 한다.

Unit 01 | Monte Carlo & Markov Chain

Monte Carlo estimating circle area



예시) > 내가 돌을 던진 모든 횟수는 정사각형의 면적에 대응하고,
저 원의 내부에 떨어진 돌의 횟수는 원의 면적에 대응한다.

원 내부에 위치한 (x,y) 의 개수 : 모든 점의 개수 = 원의 면적 : 정사각형 면적



$$\text{원의 면적} = \text{정사각형 면적} \times \frac{\text{원 내부에 위치한 } (x,y) \text{의 개수}}{\text{모든 점의 개수}}$$

Unit 01 | Monte Carlo & Markov Chain

‘마르코프 연쇄’

확률론에서, 마르코프 연쇄(Марков連鎖, 영어: Markov chain)는 Markov Property를 갖는 이산 시간 확률 과정이다.

마르코프 연쇄는 시간에 따른 계의 상태의 변화를 나타낸다.

매 시간마다 계는 상태를 바꾸거나 같은 상태를 유지한다. 상태의 변화를 '전이' 라 한다.

마르코프 성질은 과거와 현재 상태가 주어졌을 때의 미래 상태의 조건부 확률 분포가 과거 상태와는 독립적으로 현재 상태에 의해서만 결정된다는 것을 뜻한다.

Unit 01 | Monte Carlo & Markov Chain

– 체인? \Rightarrow 상태값의 시퀀스! Ex) 상태 : (비 or 맑음) $\rightarrow P(\text{Day10=비} | \text{Day9=비}, \dots, \text{Day1=맑음})$

– Markov Property(**memory = 1**)

$$Pr(X_n = x_n \mid X_{n-1} = x_{n-1}, \dots, X_1 = x_1) = Pr(X_n = x_n \mid X_{n-1} = x_{n-1})$$

\Rightarrow 현재의 상태는 바로 이전의 상태에만 영향을 받고, 그 이전의 상태와는 독립이다.

– Markov Property(**memory = m**)

$$Pr(X_n = x_n \mid X_{n-1} = x_{n-1}, \dots, X_1 = x_1) = Pr(X_n = x_n \mid X_{n-1} = x_{n-1}, X_{n-2} = x_{n-2}, \dots, X_{n-m} = x_{n-m})$$

Unit 01 | Monte Carlo & Markov Chain

– 체인? \Rightarrow 상태값의 시퀀스! Ex) 상태 : (비 or 맑음) $\rightarrow P(\text{Day10=비} | \text{Day9=비}, \dots, \text{Day1=맑음})$

– Markov Property(**memory = 1**)

$$Pr(X_n = x_n | \underbrace{X_{n-1} = x_{n-1}, \dots, X_1 = x_1}_{\text{red dashed box}}) = Pr(X_n = x_n | \underbrace{X_{n-1} = x_{n-1}}_{\text{blue underline}})$$


\Rightarrow 현재의 상태는 바로 이전의 상태에만 영향을 받고, 그 이전의 상태와는 독립이다.

– Markov Property(**memory = m**)


$$Pr(X_n = x_n | X_{n-1} = x_{n-1}, \dots, X_1 = x_1) = Pr(X_n = x_n | X_{n-1} = x_{n-1}, X_{n-2} = x_{n-2}, \dots, X_{n-m} = x_{n-m})$$

Unit 01 | Monte Carlo & Markov Chain

- 예시



(Cup) A

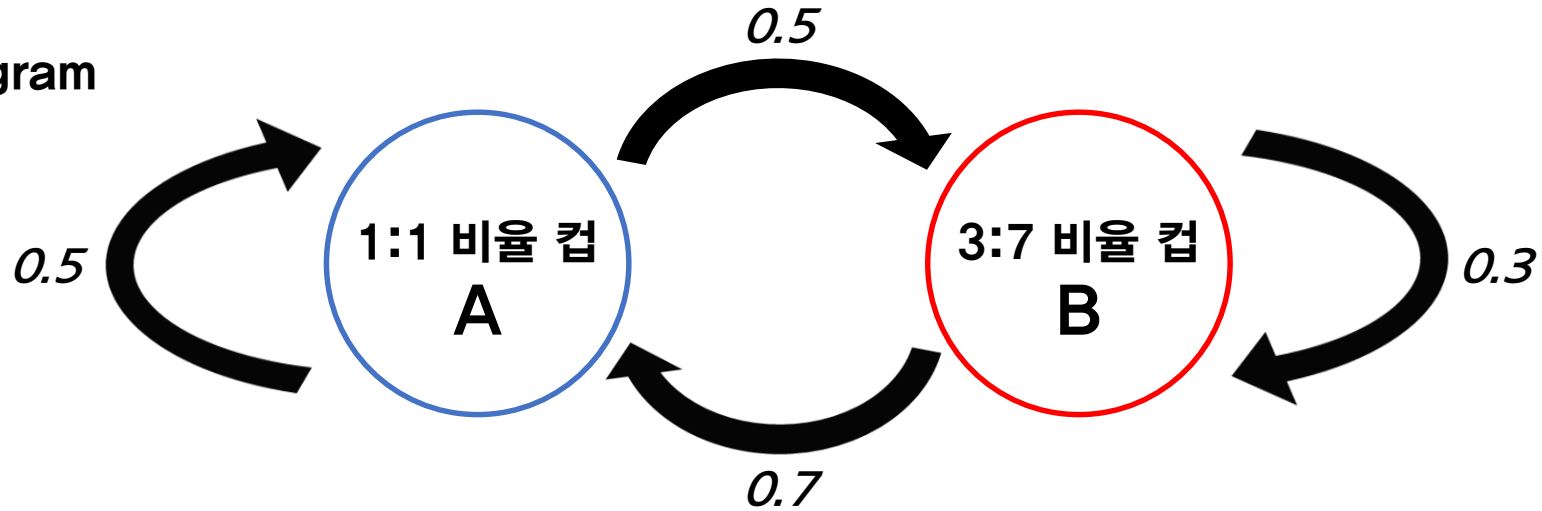


B

- ① 왼쪽 컵에서 흰 공이 나오면 다시 공을 넣고 왼쪽 컵에서 뽑는다.
- ② 왼쪽 컵에서 검은 공이 나오면 다시 공을 넣고 왼쪽 컵에서 뽑는다.
- ③ 오른쪽 컵에서 검은 공이 나오면 다시 공을 넣고 오른쪽 컵에서 뽑는다.
- ④ 오른쪽 컵에서 흰 공이 나오면 다시 공을 넣고 왼쪽 컵에서 뽑는다.

Unit 01 | Monte Carlo & Markov Chain

– State Diagram



– 전이 확률

$$A_{ij} = \begin{bmatrix} 0.5 & 0.5 \\ 0.7 & 0.3 \end{bmatrix} \quad a_{ij} : i\text{상태에서 } j\text{상태로 전이할 확률}$$

Unit 01 | Monte Carlo & Markov Chain

과정이 두 번 반복된다면?

$$\begin{bmatrix} 0.5 & 0.5 \\ 0.7 & 0.3 \end{bmatrix} \begin{bmatrix} 0.5 & 0.5 \\ 0.7 & 0.3 \end{bmatrix} = \begin{bmatrix} 0.60 & 0.40 \\ 0.56 & 0.44 \end{bmatrix} \quad a_{ij} : i\text{상태에서 } j\text{상태로 두 번의 공 뽑기 후 전이할 확률}$$

과정이 무한히 반복된다면?

$$\begin{bmatrix} 0.5 & 0.5 \\ 0.7 & 0.3 \end{bmatrix} \begin{bmatrix} 0.5 & 0.5 \\ 0.7 & 0.3 \end{bmatrix} \cdots \begin{bmatrix} 0.5 & 0.5 \\ 0.7 & 0.3 \end{bmatrix} = \begin{matrix} W & B \\ \begin{bmatrix} \frac{7}{12} & \frac{5}{12} \\ \frac{7}{12} & \frac{5}{12} \end{bmatrix} \end{matrix} \quad \text{'정상 분포(Stationary distribution)'}$$

Unit 01 | Monte Carlo & Markov Chain

‘Markov Chain Monte Carlo Method’ (MCMC)

우리가 샘플을 얻으려고 하는 목표 분포를 **정상 분포(Stationary distribution)**로 가지는 마코프 체인을 만든다.

체인의 시뮬레이션을 시작하고, 초기값에 영향을 받는 **burn-in period**를 지나고 나면 목표 분포를 따르는 샘플을 얻을 수 있다.

Unit 01 | Monte Carlo & Markov Chain

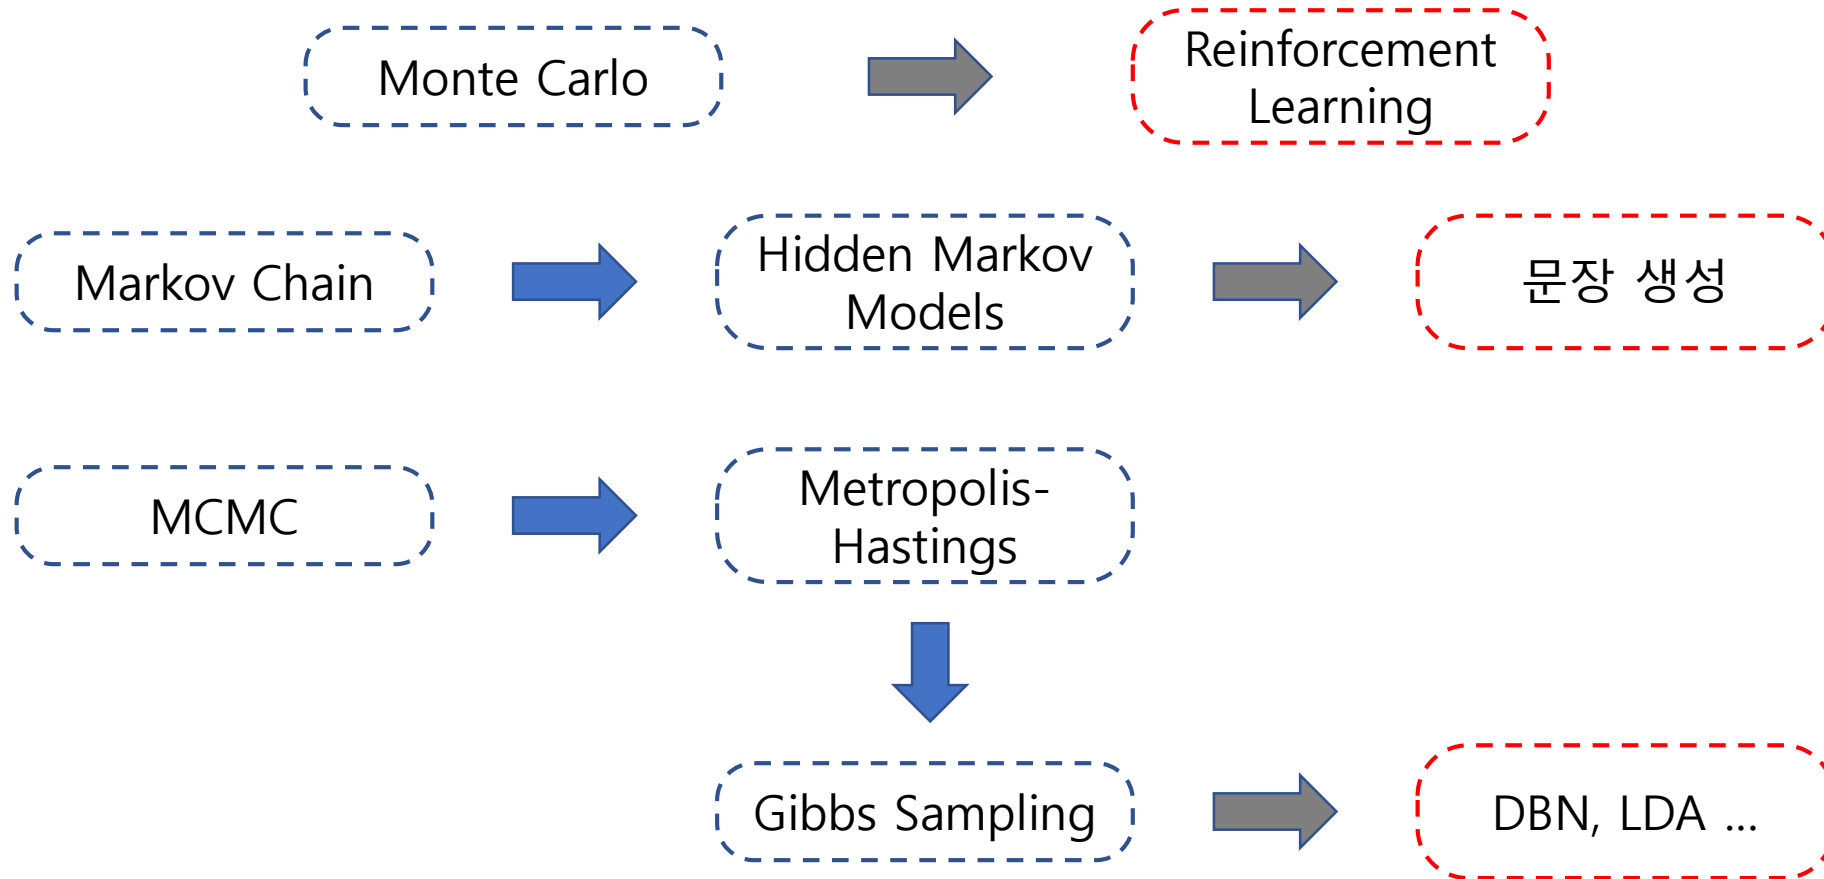
‘Markov Chain Monte Carlo Method’ (MCMC)

우리가 샘플을 얻으려고 하는 목표 분포를 **정상 분포(Stationary distribution)**로 가지는 마코프 체인을 만든다.

체인의 시뮬레이션을 시작하고, 초기값에 영향을 받는 **burn-in period**를 지나고 나면 목표 분포를 따르는 샘플을 얻을 수 있다.

- ① 마코프 체인을 위한 초기값 X_0 를 지정한다.
 - ② 마코프 체인이 정상 분포에 도달할 때까지 n 개의 관측값(마코프 수열), $\{X_k, k = 1, \dots, n\}$ 을 생성한다.
 - ③ 적당한 수렴진단 방법을 이용하여 알고리즘의 수렴 여부를 확인한다. 만약 수렴하지 않으면, 더 많은 관측값을 생성한다.
- 마코프 체인이 정상 분포에 수렴하는지 여부를 확인하고, 초기 B 개의 관측값을 제거한 후(burn-in),
 $\{X_{B+1}, \dots, X_n\}$ 을 분석을 위한 표본으로 채택한다.

Unit 01 | Monte Carlo & Markov Chain



Unit 02 | MCMC : Metropolis-Hastings

M.H. Algorithm

MH 알고리즘의 기본 아이디어는 **마코프 체인의 정상 분포가 $f(x)$ 가 되도록** 마코프 체인 $\{X_k, k = 1, \dots, n\}$ 을 생성, 적절한 전이확률을 통해 다음 상태 X_{t+1} 를 생성하는 것으로, 이를 위하여 **거절법(rejection sampling)**을 사용한다.

- 1) 현재 상태(current state) X_t 에 기반한 적절한 제안 분포 $g(\cdot | X_t)$ 로부터 후보(candidate) 난수를 생성한다!
- 2) 후보난수 Y 가 채택된다면, 마코프 체인의 다음 상태 X_{t+1} 은 Y 가 되고, $X_{t+1} = Y$ 기각된다면, 현재 상태 X_t 에 머물게 된다($X_{t+1} = X_t$).

Unit 02 | MCMC : Metropolis-Hastings

– Process

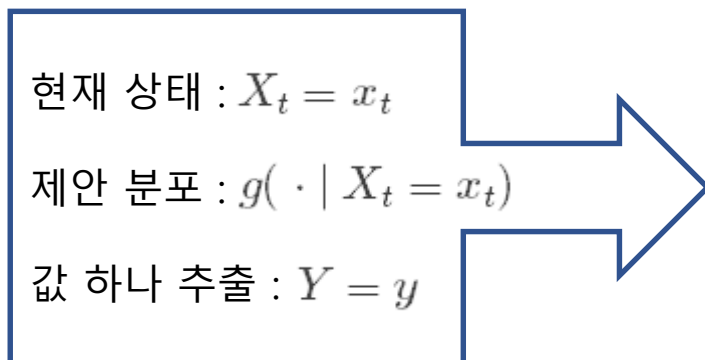
- 1 우리가 잘 알고 있는, 표본을 쉽게 추출할 수 있는 분포 $g(\cdot | X_t)$ (proposal distribution)를 하나 정한다.
(체인의 시작점 X_0 을 정하거나, 분포 $g(\cdot | X_t)$ 로부터 추출한다.)
- 2 체인이 정상 분포로 수렴할 때까지 다음의 과정을 반복한다.

어렵지 않아요!

Unit 02 | MCMC : Metropolis-Hastings

– Process

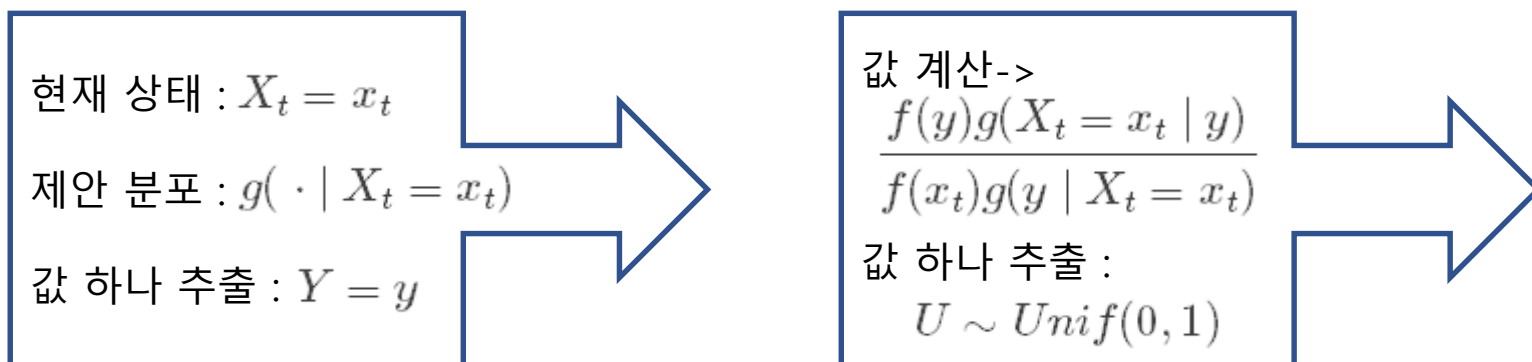
- 1 우리가 잘 알고 있는, 표본을 쉽게 추출할 수 있는 분포 $g(\cdot | X_t)$ (proposal distribution)를 하나 정한다.
(체인의 시작점 X_0 을 정하거나, 분포 $g(\cdot | X_t)$ 로부터 추출한다.)
- 2 체인이 정상 분포로 수렴할 때까지 다음의 과정을 반복한다.



Unit 02 | MCMC : Metropolis-Hastings

– Process

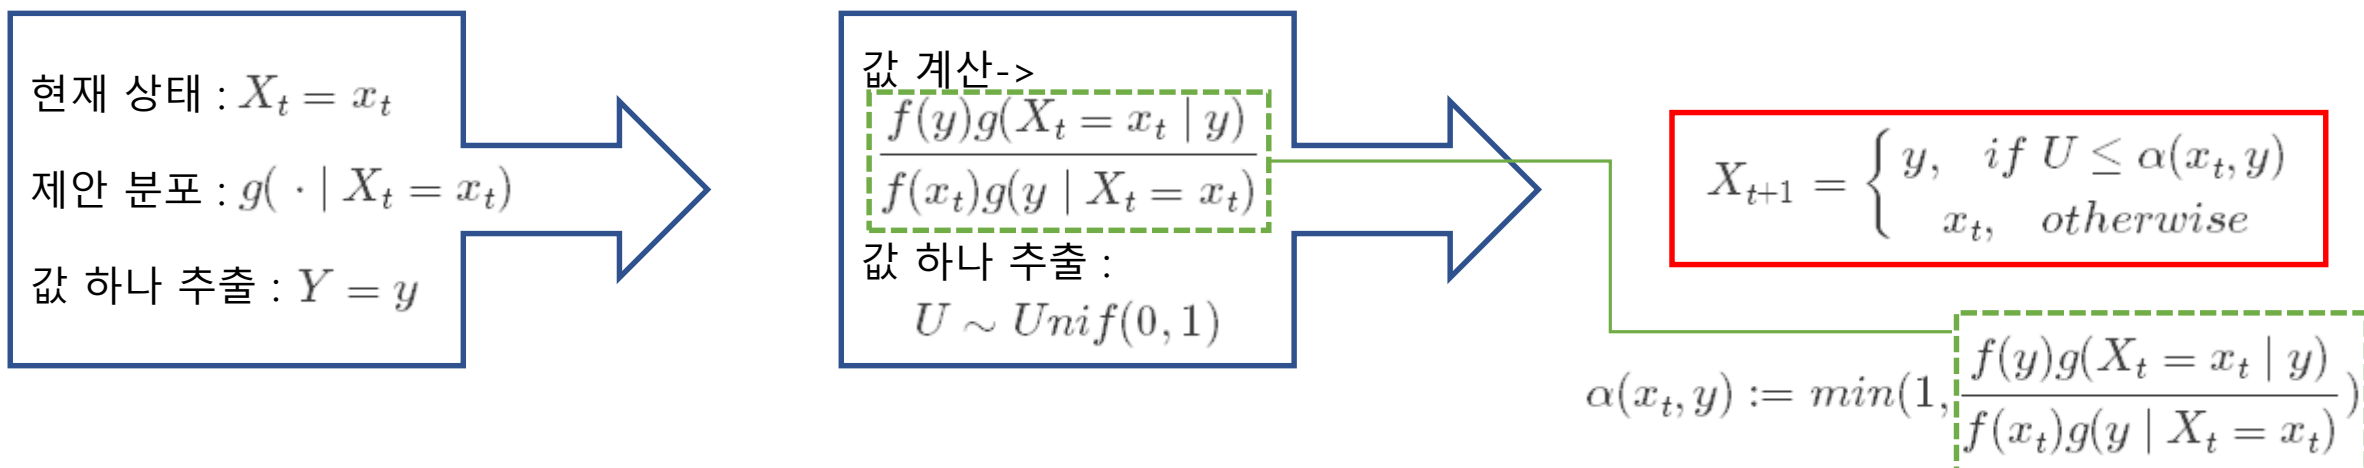
- 1 우리가 잘 알고 있는, 표본을 쉽게 추출할 수 있는 분포 $g(\cdot | X_t)$ (proposal distribution)를 하나 정한다.
(체인의 시작점 X_0 을 정하거나, 분포 $g(\cdot | X_t)$ 로부터 추출한다.)
- 2 체인이 정상 분포로 수렴할 때까지 다음의 과정을 반복한다.



Unit 02 | MCMC : Metropolis-Hastings

– Process

- 1 우리가 잘 알고 있는, 표본을 쉽게 추출할 수 있는 분포 $g(\cdot | X_t)$ (proposal distribution)를 하나 정한다.
(체인의 시작점 X_0 을 정하거나, 분포 $g(\cdot | X_t)$ 로부터 추출한다.)
- 2 체인이 정상 분포로 수렴할 때까지 다음의 과정을 반복한다.



Unit 02 | MCMC : Metropolis-Hastings

– Example

▶ 목표 분포(정상 분포) : $f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$

Unit 02 | MCMC : Metropolis-Hastings

– Example

▶ 목표 분포(정상 분포) : $f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$

▶ 제안 분포 : $g(y|X_t) = \begin{cases} \frac{1}{2}, & X_t - 1 \leq y \leq X_t + 1 \\ 0, & \text{그 외.} \end{cases}$

Unit 02 | MCMC : Metropolis-Hastings

- Example

▶ 목표 분포(정상 분포) : $f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$ ▶ 제안 분포 : $g(y|X_t) = \begin{cases} \frac{1}{2}, & X_t - 1 \leq y \leq X_t + 1 \\ 0, & \text{그 외.} \end{cases}$

▶ Acceptance probability : $\alpha(x_t, y) = \left(\frac{e^{-y^2/2}}{\sqrt{2\pi}}\right) \cdot \frac{1}{2} / \left(\frac{e^{-x_t^2/2}}{\sqrt{2\pi}}\right) \cdot \frac{1}{2} = \exp\left(-\frac{y^2 - x_t^2}{2}\right)$

▶
$$X_{t+1} = \begin{cases} y, & \text{if } U \leq \alpha(x_t, y) \\ x_t, & \text{otherwise} \end{cases}$$



Unit 02 | MCMC : Metropolis-Hastings

- Example

▶ $X_0 = -10$

▶ 목표 분포(정상 분포) : $f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$

▶ 제안 분포 : $g(y|X_t) = \begin{cases} \frac{1}{2}, & X_t - 1 \leq y \leq X_t + 1 \\ 0, & \text{그 외.} \end{cases}$



Burn-in period?

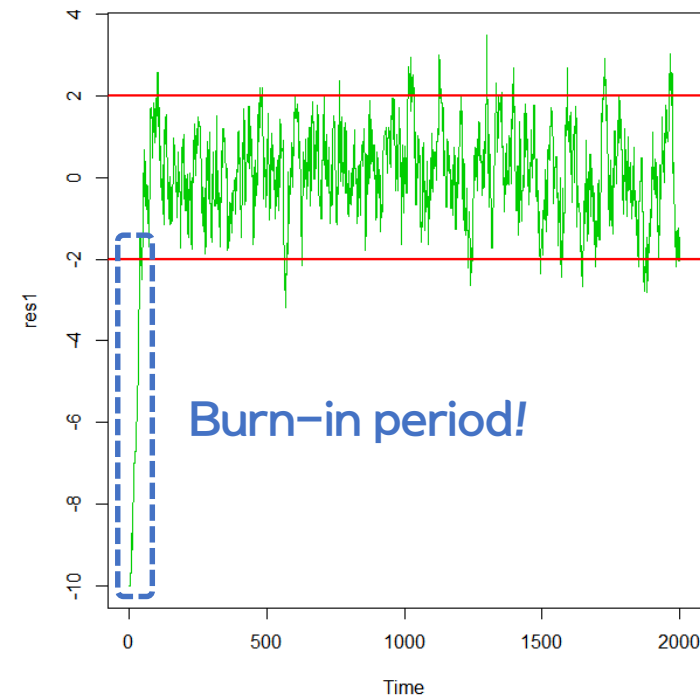
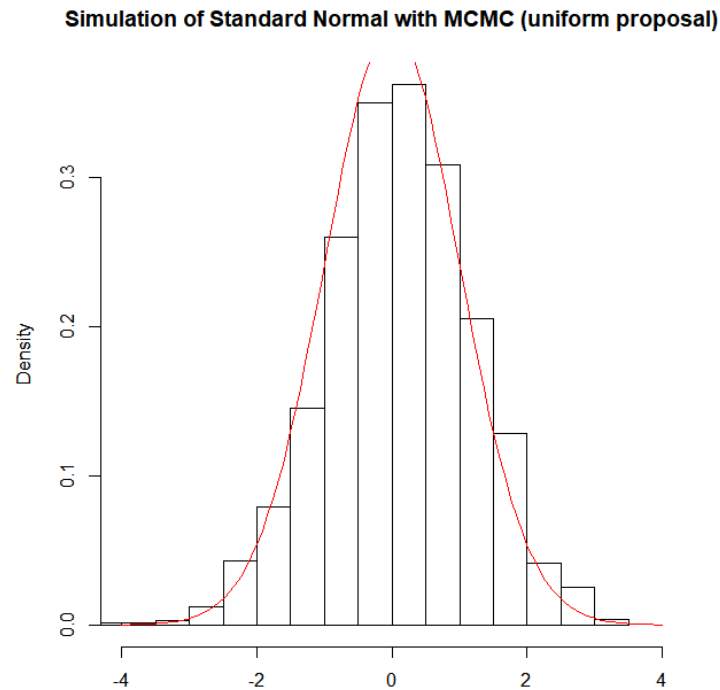
Unit 02 | MCMC : Metropolis-Hastings

- Example

▶ $X_0 = -10$

▶ 목표 분포(정상 분포) : $f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$

▶ 제안 분포 : $g(y|X_t) = \begin{cases} \frac{1}{2}, & X_t - 1 \leq y \leq X_t + 1 \\ 0, & \text{그 외.} \end{cases}$



Unit 02 | MCMC : Metropolis-Hastings

- Traits

- 제안 분포와 목표 분포의 관계에 따라 목표 분포로의 수렴 속도가 달라질 수 있다.
- 생성된 표본들은 목표 분포를 따르지만 서로 독립이 아니고 상관관계가 존재한다.
-> 상관관계를 줄이기 위해 예를 들어 매 세 번째마다 난수를 표본으로 추출하는 **Thinning** 작업을 하기도 함(**표집시차 = 3**)
- 마코프 체인이 목표 분포로 도달해 표본을 얻기 위해 얼마나 많이 반복해야 하는지에 대해 정확히 알 수는 없지만, 흔히 **trace plot**이나 **자기상관계수 확인** 등의 시각적인 방법을 사용하며, 수렴 여부를 확인하기 위한 통계량 또한 이용 가능
- 일반적으로 **full conditional probability**를 구할 수 없을 때 사용한다
(구할 수 있을 때는 Gibbs sampling이 효율적!)

Unit 03 | MCMC : Gibbs Sampling

Gibbs Sampling

What is it?




Special case of
MH algorithm!

Unit 03 | MCMC : Gibbs Sampling

Gibbs Sampling

When we use?



-> 목표 분포가 **다변량 분포**일 때!

-> 모든 **단변량 조건부 p.d.f**가 알려진 형태, 난수 추출이 쉬울 때!

-> k 차원 다변량 확률변수 $\mathbf{X} = (X_1, \dots, X_k)$ 와

k-1차원 확률변수 $\mathbf{X}_{(-j)} = (X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_k)$,

$j=1, \dots, k$ 에 대해 완전 조건부분포인 $\mathbf{X}_{(-j)}$ 가 주어졌을 때

X_j 의 단변량 조건부 p.d.f $f(X_j | \mathbf{X}_{(-j)})$ 를 고려

Unit 03 | MCMC : Gibbs Sampling

Gibbs Sampling

How to use?



순서대로 천천히,
차근차근 따라와봐요!

Unit 03 | MCMC : Gibbs Sampling

Gibbs Sampling

$$\rightarrow \mathbf{X}^{(0)} = (X_1^{(0)}, \dots, X_k^{(0)})$$

초기값 설정, $t = 0, 1, 2, \dots$ 에 대해 다음을 반복

How to use?



Unit 03 | MCMC : Gibbs Sampling

Gibbs Sampling

$$\rightarrow \mathbf{X}^{(0)} = (X_1^{(0)}, \dots, X_k^{(0)})$$

초기값 설정, $t = 0, 1, 2, \dots$ 에 대해 다음을 반복

$$\rightarrow X_1^{(t+1)} \mid \underline{\mathbf{x}_{(-1)}} \sim f(\underline{x_1} \mid x_2^{(t)}, \dots, x_k^{(t)}),$$

How to use?



Unit 03 | MCMC : Gibbs Sampling

Gibbs Sampling

$$\rightarrow \mathbf{X}^{(0)} = (X_1^{(0)}, \dots, X_k^{(0)})$$

초기값 설정, $t = 0, 1, 2, \dots$ 에 대해 다음을 반복

$$\rightarrow X_1^{(t+1)} \mid \underline{\mathbf{x}_{(-1)}} \sim f(\underline{x_1} \mid x_2^{(t)}, \dots, x_k^{(t)}),$$

$$X_2^{(t+1)} \mid \underline{\mathbf{x}_{(-2)}} \sim f(\underline{x_2} \mid \underline{x_1^{(t+1)}}^{(t)}, x_3^{(t)}, \dots, x_k^{(t)}),$$

How to use?



Unit 03 | MCMC : Gibbs Sampling

Gibbs Sampling

$$\rightarrow \mathbf{X}^{(0)} = (X_1^{(0)}, \dots, X_k^{(0)})$$

초기값 설정, $t = 0, 1, 2, \dots$ 에 대해 다음을 반복

$$\begin{aligned} \rightarrow X_1^{(t+1)} &| \underline{\mathbf{x}_{(-1)}} \sim f(x_1 | x_2^{(t)}, \dots, x_k^{(t)}), \\ X_2^{(t+1)} &| \underline{\mathbf{x}_{(-2)}} \sim f(x_2 | x_1^{(t+1)}, x_3^{(t)}, \dots, x_k^{(t)}), \\ &\vdots \\ X_{k-1}^{(t+1)} &| \mathbf{x}_{(-k+1)} \sim f(x_{k-1} | x_1^{(t+1)}, x_2^{(t+1)}, \dots, x_{k-2}^{(t+1)}, x_k^{(t)}), \\ X_k^{(t+1)} &| \mathbf{x}_{(-k)} \sim f(x_k | x_1^{(t+1)}, x_2^{(t+1)}, \dots, x_{k-1}^{(t+1)}) \end{aligned}$$

How to use?



Unit 03 | MCMC : Gibbs Sampling

– Example

* 이변량 정규분포

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N \left[\begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right]$$



분포의 p.d.f도 모르고, 난수 추출 방법도 몰라요!

Unit 03 | MCMC : Gibbs Sampling

– Example

* 이변량 정규분포

<Full conditional prob.>

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N \left[\begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right]$$



$$\begin{aligned} X_1|X_2 &\sim N(\theta_1 + \rho(X_2 - \theta_2), 1 - \rho^2), \\ X_2|X_1 &\sim N(\theta_2 + \rho(X_1 - \theta_1), 1 - \rho^2). \end{aligned}$$




분포의 p.d.f도 모르고, 난수 추출 방법도 몰라요!

Unit 03 | MCMC : Gibbs Sampling

– Example

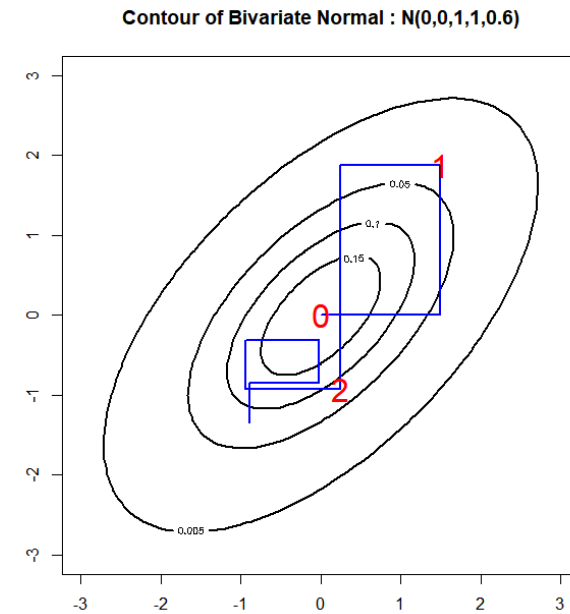

* 이변량 정규분포



Unit 03 | MCMC : Gibbs Sampling

– Example

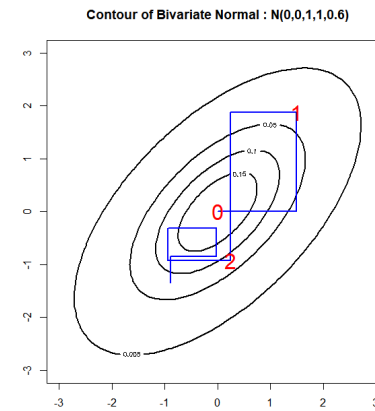

* 이변량 정규분포



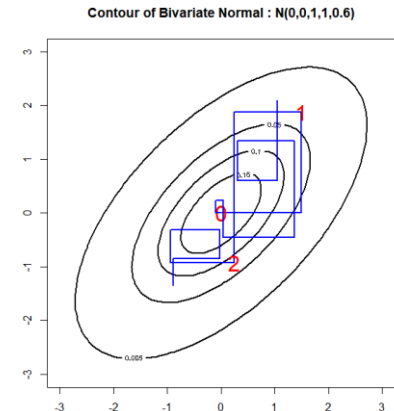
Unit 03 | MCMC : Gibbs Sampling

– Example

* 이변량 정규분포





...



Unit 03 | MCMC : Gibbs Sampling

– Example

* 이변량 정규분포



Q & A

감사합니다!



감사합니다?? ㅎㅎ 아직!

과제

– Easy!

이변량 분포의 two-dimensional p.d.f가 다음과 같이 있다.

$$f(x_1, x_2) = 2 \exp(-x_1 x_2 - x_1 - x_2), \quad x_1 > 0, \quad x_2 > 0$$

깁스 샘플링을 사용해서, 사이즈 $n = 10^3$ 의 random vector $\{(X_{1i}, X_{2i})\}_{i=1}^n$ 를 생성하라. (burn-in period 꼭 고려하기!)
생성한 두 확률변수 샘플은 joint p.d.f $f(x_1, x_2)$ 를 따를 것이다.

<꼭 해주셔야 할 것!>

1. x_1, x_2 의 marginal p.d.f 구하기
2. 2차원의 contour(등고선) 그래프 시각화하고 확인하기
3. 2차원 산점도를 그리고 목표 분포의 모양새 추정해보기